MACHINE LEARNING: CAR CLAIMS

BALDINI, D'ANGELO, LUCCHESI, VITOLLA.

DESCRIZIONE DATASET

Il dataset **"Carclaims"** è un dataset relativo ai sinistri automobilistici in ambito assicurativo. Comprende **15.420 osservazioni**, suddivise in **14.497 sinistri legittimi** e **923 fraudolenti**, evidenziando un significativo sbilanciamento tra le classi (**94% "No" vs 6% "Yes"**).

Le variabili disponibili includono **32 covariate** di natura sia categorica che numerica, oltre alla variabile target binaria **"FraudFound"**, che indica la presenza o l'assenza di frode.

L'obiettivo del progetto è sviluppare un modello predittivo in grado di identificare le richieste di risarcimento fraudolente basandosi sulle informazioni fornite dalle covariate.

PREPROCESSING GENERALE

Near-zero-variance

	freqRatio	percentUnique	zeroVar	nzv
Month	1.032187	0.07782101	FALSE	FALSE
WeekOfMonth	1.023047	0.03242542	FALSE	FALSE
DayOfWeek	1.069939	0.04539559	FALSE	FALSE
Make	1.229414	0.12321660	FALSE	FALSE
AccidentArea	8.649562	0.01297017	FALSE	FALSE
DayOfWeekClaimed	1.113185	0.05188067	FALSE	FALSE
MonthClaimed	1.024805	0.08430610	FALSE	FALSE
WeekOfMonthClaimed	1.038236	0.03242542	FALSE	FALSE
Sex	5.371901	0.01297017	FALSE	FALSE
MaritalStatus	2.268360	0.02594034	FALSE	FALSE
Age	1.038328	0.42801556	FALSE	FALSE
Fault	2.680191	0.01297017	FALSE	FALSE
PolicyType	1.119711	0.05836576	FALSE	FALSE
VehicleCategory	1.804965	0.01945525	FALSE	FALSE
VehiclePrice	2.286725	0.03891051	FALSE	FALSE
PolicyNumber	1.000000	100.00000000	FALSE	FALSE
RepNumber	1.070070	0.10376135	FALSE	FALSE
Deductible	47.710611	0.02594034	FALSE	TRUE
DriverRating	1.015448	0.02594034	FALSE	FALSE
Days.Policy.Accident	277.218182	0.03242542	FALSE	TRUE
Days.Policy.Claim	273.964286	0.02594034	FALSE	TRUE
PastNumberOfClaims	1.260340	0.02594034	FALSE	FALSE
AgeOfVehicle	1.458679	0.05188067	FALSE	FALSE
AgeOfPolicyHolder	1.383379	0.05836576	FALSE	FALSE
PoliceReportFiled	35.028037	0.01297017	FALSE	TRUE
WitnessPresent	176.241379	0.01297017	FALSE	TRUE
AgentType	62.983402	0.01297017	FALSE	TRUE
NumberOfSuppliments	1.822343	0.02594034	FALSE	FALSE
AddressChange.Claim	22.700475	0.03242542	FALSE	TRUE
NumberOfCars	20.191819	0.03242542	FALSE	TRUE
Year	1.182291	0.01945525	FALSE	FALSE
BasePolicy	1.190258	0.01945525	FALSE	FALSE
FraudFound	15.706392	0.01297017	FALSE	FALSE

Sono state omesse le variabili con nzv = TRUE, ovvero Deductible, Days.Policy.Accident, Days.Policy.Claim, PoliceReportFiled, WitnessPresent, AgentType, AddressChange.Claim, NumberOfCars, PolicyNumber.

DATA PARTITION

Il dataset è stato così ripartito:

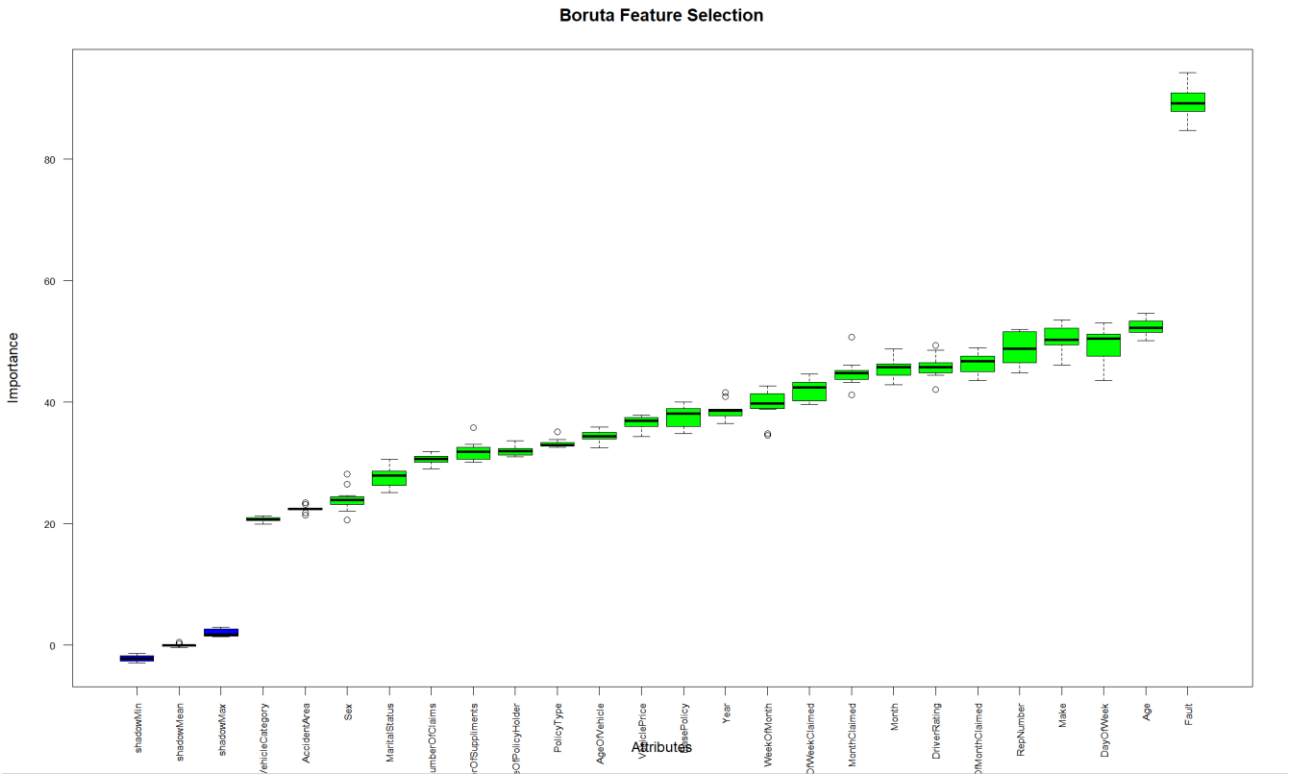
- 5% dati di score (770 osservazioni);
- 63% dati di training (9670 osservazioni);
- 32% dati di test (4980 osservazioni.

BILANCIAMENTO – OVERSAMPLING

Il train set è stato bilanciato con l'algoritmo Rose (metodo "both"), portando la distribuzione della variabile target al 50% di "Yes" e 50% di "No".

```
> summary(balanced_trainData$FraudFound)
  No  Yes
4868 4802
```

MODEL SELECTION – BORUTA



Variabili selezionate: "Fault", "RepNumber", "Age", "Make", "DayOfWeekClaimed", "Month", "MonthClaimed", "DayOfWeek", "WeekOfMonth", "DriverRating", "VehiclePrice", "WeekOfMonthClaimed", "AgeOfVehicle", "BasePolicy", "Year", "FraudFound".

Sono state selezionate le variabili la cui importanza risultasse superiore all'importanza media.

STEP 1

Addestramento modelli

I seguenti modelli sono stati addestrati, massimizzando l'AUC, sul dataset con le variabili selezionate con Boruta:

- *Logistico:* near-zero-variance, collinearità, separation, trasformazione Box-Cox*;*
- *KNN:* near-zero-variance, collinearità e standardizzazione*;*
- *PLS:* near-zero-variance, centratura*;*
- *Neural Network (NN):* near-zero-variance, standardizzazione, centratura, collinearità.

Questi altri modelli sono invece stati stimati con il dataset completo:

- *Lasso*: standardizzazione.
- *Naive Bayes*: near-zero-variance, collinearità.
- *Tree, Random Forest, Gradient Boosting*.

Valutazione overfitting

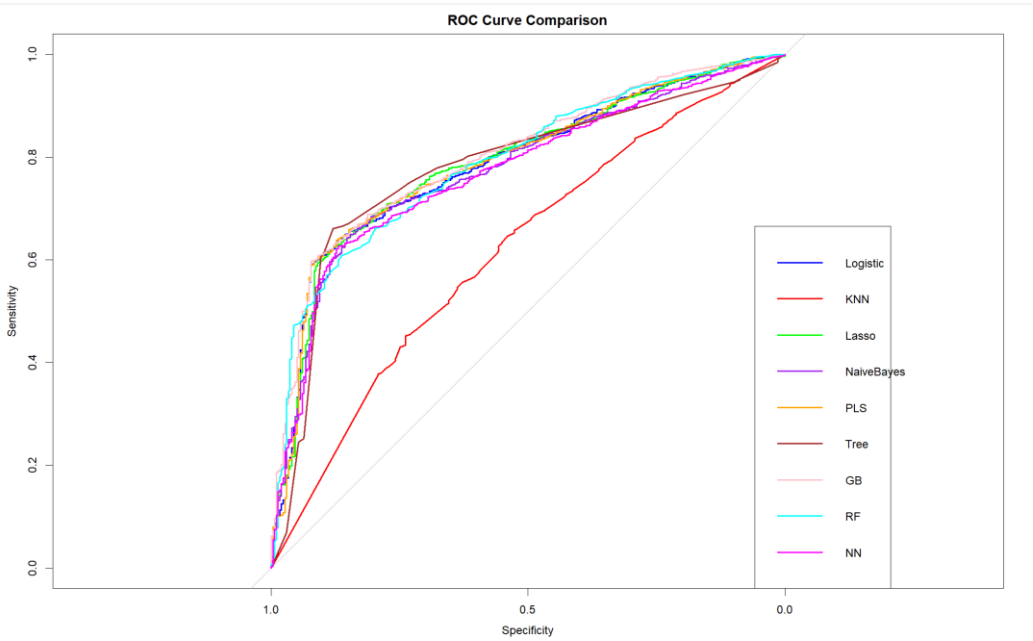
L'overfitting è stato valutato tramite l'ASE, massimizzando l'AUC, evidenziando inizialmente criticità nei modelli k-NN, Tree, Random Forest e Gradient Boosting. Dopo aver ridotto la complessità dei modelli, la situazione si è evoluta nel modo seguente:

```
> print(aseResults)
                Model  ASE_Train  ASE_Test Variazione_Percentuale
Logistic     Logistic 0.17292691 0.1815970              4.7743453
KNN               KNN 0.14262461 0.3121173             54.3041667
Lasso           Lasso 0.16692175 0.1793379              6.9233315
NaiveBayes NaiveBayes 0.25106704 0.2522274              0.4600636
PLS               PLS 0.19640708 0.1977583              0.6832728
Tree             Tree 0.14289237 0.1760068             18.8143133
GB                 GB 0.15674590 0.1699370              7.7623572
RF                 RF 0.06986339 0.1465507             52.3281776
NN                 NN 0.16553506 0.1893562             12.5800600
```

Modelli che presentano comunque overfitting: k-NN, Tree e Random Forest.

STEP 2

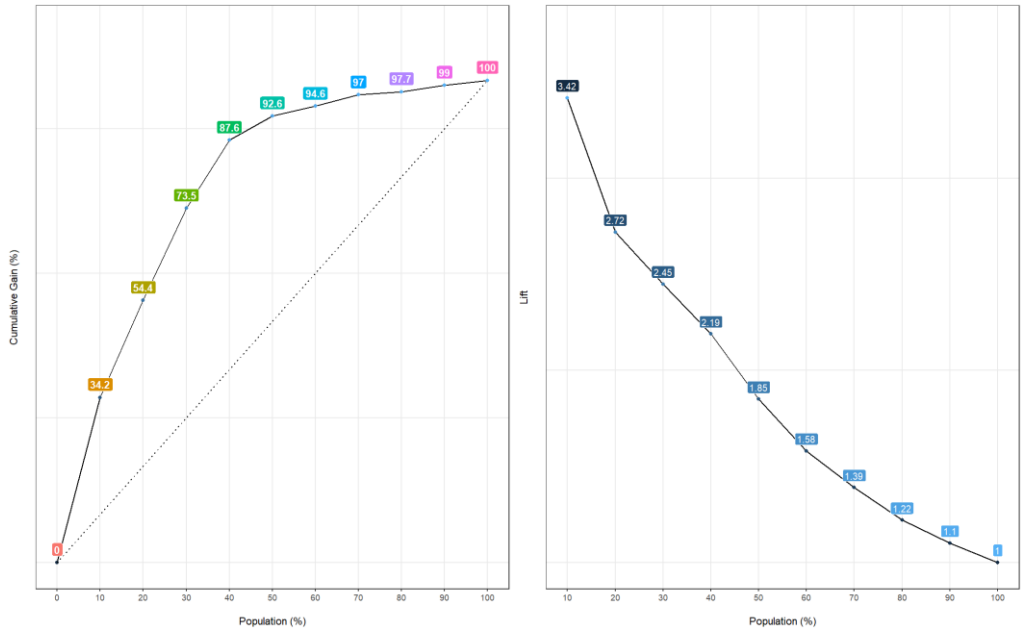
Abbiamo eseguito l'assessment dei modelli sulla base delle curve ROC.



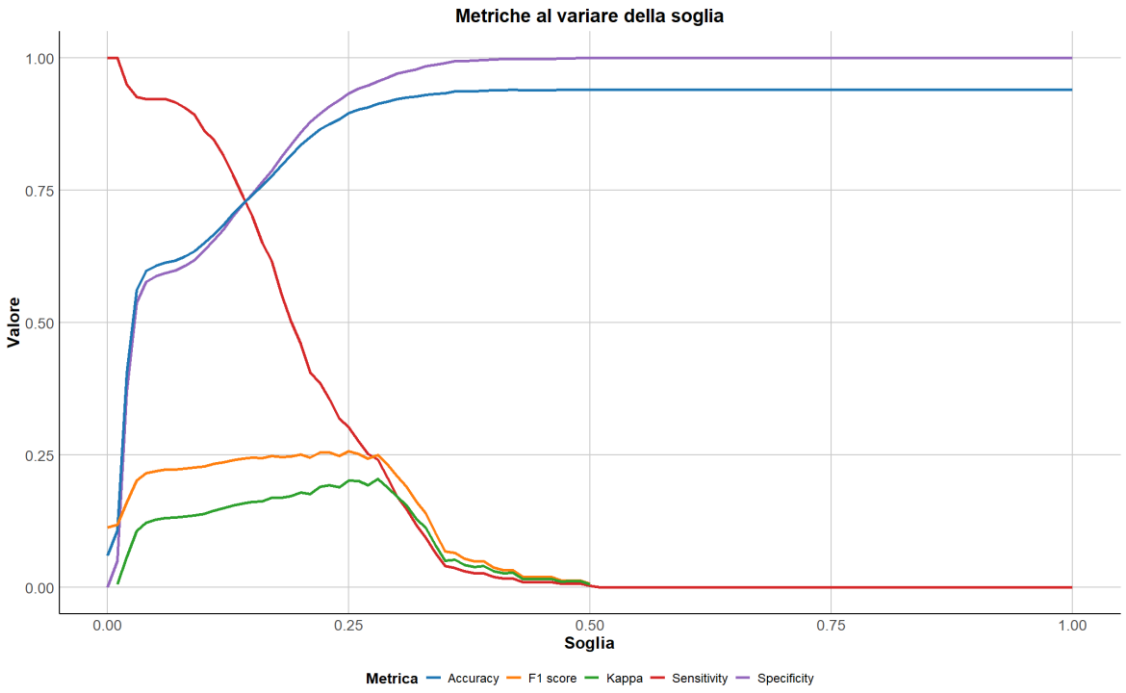
Situazione non chiara → valutazione con le curve LIFT.

Dopo aver corretto le probabilità a posteriori dei modelli considerati nell'assessment ed aver rappresentato graficamente le curve LIFT, abbiamo deciso di proseguire con un confronto puntuale dei modelli considerando il terzo decile.

Il modello con Cumulative Gain (%) maggiore in corrispondenza del terzo decile risulta essere il Gradient Boosting.



STEP 3



Consideriamo la metrica “F1 score”. La soglia che massimizza questa metrica corrisponde a 0.25.

Table: Metriche al variare della soglia (0.15 - 0.30)

	threshold	Sensitivity	Specificity	Accuracy	F1	Precision	Kappa
16	0.15	0.7013423	0.7434857	0.7409639	0.2447307	0.1482270	0.1619312
17	0.16	0.6510067	0.7656984	0.7588353	0.2441787	0.1502711	0.1627714
18	0.17	0.6174497	0.7866296	0.7765060	0.2484808	0.1555368	0.1690434
19	0.18	0.5536913	0.8129005	0.7973896	0.2464526	0.1585014	0.1691469
20	0.19	0.5033557	0.8361811	0.8162651	0.2469136	0.1635769	0.1721365
21	0.20	0.4597315	0.8596754	0.8357430	0.2509158	0.1725441	0.1795181
22	0.21	0.4060403	0.8786843	0.8504016	0.2451874	0.1756168	0.1763782
23	0.22	0.3859060	0.8953439	0.8648594	0.2547065	0.1900826	0.1897369
24	0.23	0.3557047	0.9085861	0.8755020	0.2548077	0.1985019	0.1928046
25	0.24	0.3187919	0.9203332	0.8843373	0.2480418	0.2029915	0.1887214
26	0.25	0.3020134	0.9331482	0.8953815	0.2567760	0.2233251	0.2018622
27	0.26	0.2751678	0.9423323	0.9024096	0.2523077	0.2329545	0.2004910
28	0.27	0.2516779	0.9478855	0.9062249	0.2431118	0.2351097	0.1931896
29	0.28	0.2416107	0.9562153	0.9134538	0.2504348	0.2599278	0.2045754
30	0.29	0.2080537	0.9628364	0.9176707	0.2322097	0.2627119	0.1893321
31	0.30	0.1711409	0.9705254	0.9226908	0.2094456	0.2698413	0.1709389

Il modello non è soddisfacente.

STEP 4

Risultati applicazione del modello Gradient Boosting sul dataset di score (dopo aver corretto le posteriors).

```
Confusion Matrix and Statistics

          Reference
Prediction  No Yes
       No  675  36
       Yes  49  10

               Accuracy : 0.8896
                 95% CI : (0.8653, 0.9109)
    No Information Rate : 0.9403
    P-Value [Acc > NIR] : 1.0000

                  Kappa : 0.1322

 Mcnemar's Test P-Value : 0.1931

            Sensitivity : 0.21739
            Specificity : 0.93232
         Pos Pred Value : 0.16949
         Neg Pred Value : 0.94937
             Prevalence : 0.05974
         Detection Rate : 0.01299
   Detection Prevalence : 0.07662
      Balanced Accuracy : 0.57486

       'Positive' Class : Yes
```

Precision: 0.1694915

F1-Score: 0.1904762